

Reporte Técnico de Actividades Práctico-Experimentales Nro. 007

Universidad Nacional de Loja
Facultad de la Energía, las Industrias y los Recursos Naturales No Renovables
Carrera de Computación

Nombre del estudiante(s)	Wilson Palma
Asignatura	Metodología de la Investigación en Computación
Ciclo	4 A
Unidad	1
Resultado de aprendizaje de la unidad	R1. Contrasta la investigación y sus tipos con los métodos en el área de Computación y afines.
Práctica Nro.	007
Título de la Práctica	Documento del proyecto y repositorio GitHub
Nombre del Docente	Luis Antonio Chamba Eras
Fecha	Martes 26 de mayo de 2026
Horario	10h30 – 11h30
Lugar	EVA-Moodle / Aula
Tiempo planificado en el Sílabo	1 hora

Índice

1. Objetivo(s) de la Práctica	3
2. Materiales y reactivos	3
3. Equipos y herramientas	3
4. Procedimiento / Metodología Ejecutada	3
5. Resultados esperados	3
5.1. Introducción	3
5.2. Tema de investigación	4
5.3. Desarrollo del proceso investigativo	4
5.3.1. Búsqueda inicial de artículos (APE2)	4
5.3.2. Análisis de brechas y problemas (APE3)	10
5.3.3. Análisis de enfoques de investigación (ACD3)	12
5.3.4. Mapa conceptual del problema (AA3)	15

5.3.5. Formulación de objetivos y pregunta de investigación (APE4)	16
5.3.6. Recolección de 20 fuentes bibliográficas (APE5)	17
5.3.7. Estrategia de búsqueda avanzada (APE6)	22
5.3.8. Redacción de antecedentes iniciales (AA6)	28
5.4. Estado actual del proyecto	29
5.5. Preguntas de control	30
5.6. Conclusiones	30
6. Referencias	30
7. Anexos	33

1. Objetivo(s) de la Práctica

Crear el documento editable del proyecto integrador en Overleaf o Google Docs y configurar la estructura básica del repositorio GitHub.

2. Materiales y reactivos

- Computador.
- Overleaf o Google Docs.
- GitHub.
- Plantilla del documento del proyecto.

3. Equipos y herramientas

EVA-Moodle; guía institucional de práctica.

4. Procedimiento / Metodología Ejecutada

1. Crear el documento del proyecto en Overleaf (LaTeX) o Google Docs.
2. Configurar la estructura: portada, índice, introducción, planteamiento del problema, objetivos, marco referencial y referencias.
3. Vincular Mendeley o Zotero con el documento para gestión de citas.
4. Crear repositorio GitHub con README y carpetas docs, src, data y refs.
5. Subir el primer commit con la estructura del proyecto.
6. Subir el reporte técnico y el enlace del repositorio a EVA-Moodle.

5. Resultados esperados

5.1. Introducción

La clasificación automática de texto es una tarea central en minería de texto, aprendizaje automático y procesamiento de lenguaje natural, debido a su utilidad para organizar información, reducir carga manual y apoyar la toma de decisiones. Dentro de este campo, Naive Bayes destaca por su simplicidad, eficiencia computacional y buen desempeño como modelo base. Sin embargo, la literatura muestra que su rendimiento puede verse afectado por problemas de estimación de parámetros, independencia condicional, desbalance de clases, representación de características y tamaño del conjunto de datos [1]–[10].

En este contexto, el presente reporte técnico integra de manera unificada el proceso desarrollado durante la unidad, desde la búsqueda inicial de literatura hasta la redacción de antecedentes. La investigación se enmarca en la línea institucional de la Universidad Nacional de Loja denominada “**Tecnologías de la Computación para la Innovación Tecnológica, Desarrollo Sostenible y la Transformación Digital**”, la cual incluye sublíneas directamente relacionadas con inteligencia artificial, aprendizaje automático, ciencia de datos y procesamiento de lenguaje natural [11].

Este reporte no se limita a presentar resultados aislados. Su propósito es documentar la trazabilidad completa del proyecto, mostrar cómo evolucionó la pregunta de investigación, evidenciar la construcción progresiva del marco bibliográfico y consolidar el estado actual del trabajo en un repositorio GitHub organizado con fines académicos y de seguimiento.

5.2. Tema de investigación

El tema de investigación consolidado es:

Efectividad de Naive Bayes en la clasificación de texto

A partir de la revisión realizada, la pregunta central se formuló como:

¿Qué tan efectivo es Naive Bayes en clasificación de texto?

La elección del tema responde a que Naive Bayes sigue siendo una técnica ampliamente utilizada en tareas textuales por su bajo costo computacional y facilidad de implementación, pero su desempeño real depende de múltiples factores. Los estudios revisados muestran mejoras relevantes cuando se incorporan técnicas de normalización, ponderación de características, selección de atributos, manejo del desbalance, suavizado, modelos de orden superior y adaptaciones semánticas [1]–[15].

Desde la perspectiva académica, el tema también es pertinente porque se articula con la sublínea de **Inteligencia Artificial y Aprendizaje Automático** de la línea de investigación institucional, así como con el itinerario de **Sistemas Inteligentes** [11]. En consecuencia, el estudio no solo tiene interés metodológico, sino también alineación institucional y aplicabilidad en problemas de clasificación textual presentes en distintos dominios.

5.3. Desarrollo del proceso investigativo

5.3.1. Búsqueda inicial de artículos (APE2)

La primera etapa del proceso consistió en la búsqueda inicial de cinco artículos científicos relacionados con Naive Bayes y clasificación de texto. Esta actividad permitió establecer una base bibliográfica preliminar y comenzar a delimitar la pregunta de investigación. En esta fase se identificó que el algoritmo, aunque simple, mostraba variaciones importantes de desempeño según el contexto del corpus, el tipo de texto y las técnicas de mejora aplicadas [1]–[5].

Tabla 1: Matriz de extracción (5 artículos)

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
1	S. B. Kim, K. S. Han y H. C. Rim, "Some Effective Techniques for Naive Bayes Text Classification," IEEE Transactions on Knowledge and Data Engineering, vol. 18, no. 11, pp. 1457–1466, 2006. doi: 10.1109/TKDE.2006.180	2006	IEEE	Naive Bayes con normalización por documento y feature weighting	El Naive Bayes estándar obtiene resultados pobres en clasificación de texto por problemas en la estimación de parámetros	Mejorar el desempeño de Naive Bayes en clasificación de texto	Propuesta de dos heurísticas empíricas: normalización por documento y ponderación de características	Colecciones de referencia / benchmark estándar para clasificación de texto	El clasificador propuesto compite muy bien y puede llegar a rendir de forma cercana a clasificadores más complejos como SVM	Las heurísticas son ad hoc y dependen del ajuste experimental	Demuestra que Naive Bayes sí puede ser muy efectivo en texto cuando se lo mejora con normalización y ponderación

2	K. Sangounpao y P. Muenchaisri, "Ontology-Based Naive Bayes Short Text Classification Method for a Small Dataset," Proceedings of the 20th IEEE/ACIS International Conference on Software Engineering, Artificial Intelligence, Networking and Parallel/Distributed Computing (SNPD), pp. 53–58, 2019. doi: 10.1109/SNPD.2019.8935711	2019	IEEE	Naive Bayes basado en ontología	Clasificación de texto corto con un conjunto de datos pequeño	Proponer una metodología de clasificación basada en ontología para mejorar Naive Bayes en texto corto	Construcción de ontología y uso de esa ontología dentro del proceso de clasificación	Dataset pequeño de texto corto / contexto de clasificación breve	El artículo propone y evalúa un enfoque viable para texto corto, mostrando que la ontología ayuda a estructurar mejor la clasificación	El tamaño reducido del dataset limita la generalización	Aporta una variante útil de Naive Bayes para escenarios de texto corto y datos escasos
---	---	------	------	---------------------------------	---	---	--	--	--	---	--



3	E. Frank y R. R. Bouckaert, "Naive Bayes for Text Classification with Unbalanced Classes," in Knowledge Discovery in Databases: PKDD 2006, Lecture Notes in Computer Science, vol. 4213, pp. 503–510, 2006. doi: 10.1007/11871637_49	2006	Springer (LNCS)	Multinomial Naive Bayes con ajuste de priors	Desequilibrio de clases en clasificación de texto	Mejorar el rendimiento de MNB en datasets desbalanceados	Corrección por ajuste de priors de atributos / normalización adicional	Datasets desbalanceados para clasificación de documentos	La corrección propuesta mejora significativamente el área bajo la curva ROC	Se enfoca en MNB y en el problema de desbalance, no en todos los escenarios posibles	Muestra que Naive Bayes puede ser más efectivo cuando se corrige el sesgo por clases desbalanceadas
---	--	------	-----------------	--	---	--	--	--	---	--	---



4	D. Zhang, J. Wang, E. Yilmaz, X. Wang y Y. Zhou, "Bayesian Performance Comparison of Text Classifiers," in Proceedings of the 39th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '16), pp. 15–24, 2016. doi: 10.1145/2911451.2911547	2016	ACM	Evaluación bayesiana de clasificadores de texto	Comparar de forma confiable si un clasificador es realmente mejor que otro	Proponer un enfoque bayesiano para comparar rendimiento de clasificadores de texto	Inferencia bayesiana para comparar diferencias de desempeño y medir incertidumbre	Algoritmos representativos de clasificación de texto y un dataset de benchmark	El método ofrece información más rica que NHST; además, el artículo muestra que NBMult, cuando se mejora con TF-IDF y normalización, puede ser prácticamente equivalente a SVM bajo ciertos márgenes	No es un nuevo clasificador, sino un marco de evaluación	Ayuda a interpretar con más rigor cuán efectivo es Naive Bayes frente a otros clasificadores
---	---	------	-----	---	--	--	---	--	--	--	--



5	L. Jiang, C. Li, S. Wang y L. Zhang, "Deep feature weighting for naive Bayes and its application to text classification," Engineering Applications of Artificial Intelligence, vol. 52, pp. 26–39, 2016. doi: 10.1016/j.engappai.2016.02.002	2016	Scopus	Naive Bayes con deep feature weighting	La suposición de independencia y la forma clásica de estimar probabilidades limitan la precisión de Naive Bayes	Mejorar Naive Bayes incorporando ponderación profunda de características	Cálculo profundo de frecuencias ponderadas dentro de las probabilidades condicionales	36 datasets benchmark de UCI y aplicaciones a clasificadores Naive Bayes para texto	Rara vez empeora el modelo estándar y en muchos casos lo mejora de forma marcada; además, logra mejoras notables en clasificadores de texto basados en NB	La validación se apoya en benchmarks; requiere más procesamiento que NB básico	Refuerza la idea de que Naive Bayes puede ser muy competitivo en clasificación de texto si se mejora su representación de características
---	--	------	--------	--	---	--	---	---	---	--	---

La síntesis inicial permitió concluir que Naive Bayes no debe evaluarse solo por su versión básica, sino por su comportamiento cuando se ajusta a las características del problema. Desde esta etapa ya se observó una tendencia clara: el modelo es competitivo cuando se incorporan técnicas de mejora, especialmente en textos cortos, clases desbalanceadas y corpus con vocabulario amplio [1]–[5], [9], [13].




Figura 1: Matriz de extracción inicial de cinco artículos científicos sobre clasificación de texto con Naive Bayes.

5.3.2. Análisis de brechas y problemas (APE3)

La segunda etapa se centró en identificar brechas, limitaciones y problemas recurrentes en la literatura. El objetivo fue comprender qué obstáculos impiden que Naive Bayes alcance un desempeño más estable o generalizable en clasificación de texto.

Tabla 2: Brechas y problemas identificados

#	Tipo	Descripción	Evidencia textual	Fuente	Implicancia
---	------	-------------	-------------------	--------	-------------

1	Limitación técnica	Se identifica un fallo crítico en el proceso de estimación de parámetros de Naive Bayes cuando se aplica a lenguaje natural, lo que genera resultados decepcionantes comparados con otras tareas de minería de datos.	"found a serious problem in the parameter estimation process, which causes poor results in text classification domain".	[1]	Sugiere que el modelo estándar requiere heurísticas de normalización para ser competitivo frente a modelos complejos como SVM.
2	Brecha de conocimiento	Las investigaciones previas sobre ponderación de características han sido incompletas, ya que solo integran los pesos en la fórmula de clasificación final y omiten las estimaciones de probabilidad condicional.	"all of the existing feature weighting approaches only incorporate the learned feature weights into the classification of formula... and do not incorporate the learned feature weights into its conditional probability estimates at all".	[5]	Indica que la precisión del modelo podría mejorar significativamente mediante un pesado de características profundo en el entrenamiento.
3	Problema práctico/aplicado	El clasificador Multinomial Naive Bayes (MNB) presenta deficiencias de rendimiento sustanciales cuando se enfrenta a conjuntos de datos donde las clases no están equilibradas.	"combat a potential problem with the application of MNB to unbalanced datasets. We propose an appropriate correction by adjusting attribute priors".	[3]	Establece que la efectividad de NB depende de la distribución de los datos y requiere correcciones específicas de <i>priors</i> en contextos reales.
4	Brecha de conocimiento	Existe una falta de investigación sobre la clasificación multiclase de textos cortos (requerimientos funcionales) utilizando conjuntos de datos pequeños en dominios especializados como la contabilidad.	"There is no research on multi-classification of functional requirements with a small dataset particularly for an accounting field".	[2]	[Inferencia] La efectividad de NB en nichos técnicos está poco explorada y podría depender de la integración con ontologías para compensar la falta de datos.
5	Necesidad metodológica	Los métodos estadísticos tradicionales (frecuentistas) para comparar clasificadores de texto son insuficientes, pues no pueden aceptar la hipótesis nula ni manejar correctamente métricas como F1.	"such a frequentist approach has a number of inherent deficiencies and limitations, e.g., the inability to accept the null hypothesis... the difficulty to compare commonly-used multivariate performance measures like F1 scores".	[4]	La falta de rigor estadístico en las comparaciones previas podría estar nublando la comprensión real de qué tan "efectivo" es un clasificador frente a otro.

6	Limitación técnica	Los modelos actuales para evaluar puntajes F1 fallan al no considerar la correlación entre los clasificadores durante la comparación, lo que reduce el poder estadístico de los resultados.	"In contrast to the existing probabilistic model for F1 scores which is unpaired, our proposed model takes the correlation between classifiers into account".	[4]	[Inferencia] Muchas afirmaciones sobre la superioridad de otros modelos sobre NB podrían basarse en evaluaciones con bajo poder estadístico.
---	---------------------------	---	---	-----	---

El análisis mostró que los principales problemas de Naive Bayes no se relacionan solo con el algoritmo en sí, sino con las condiciones de aplicación. En particular, el desempeño puede degradarse por el tipo de representación textual, el balance de clases, la longitud de los documentos y la forma de evaluar comparativamente los clasificadores [3], [8], [12], [13].

Síntesis de brechas En conjunto, las fuentes estudiadas sugieren tres brechas dominantes. Primero, existe una debilidad en la estimación probabilística y en el tratamiento de las características. Segundo, hay una vulnerabilidad evidente en escenarios de datos escasos, textos breves y clases desbalanceadas. Tercero, las comparaciones entre clasificadores no siempre se realizan con el rigor estadístico suficiente para concluir con claridad qué método es realmente superior [2], [3], [9], [12], [13].

Figura 2: Matriz de análisis de brechas de estudios sobre clasificación de texto con Naive Bayes.

5.3.3. Análisis de enfoques de investigación (ACD3)

En esta etapa se clasificaron los primeros estudios de acuerdo con su enfoque de investigación. El análisis mostró que los artículos revisados responden de forma predominante a un enfoque cuantitativo, debido a que se basan en experimentación, métricas de desempeño, validación cruzada y comparación numérica de modelos.

Tabla 3: Enfoques de investigación de los cinco artículos iniciales

Artículos	Enfoque Cuantitativo	Enfoque Cualitativo	Enfoque mixto	Observación
-----------	----------------------	---------------------	---------------	-------------



unl

Universidad
Nacional
de Loja

[1]	Sí	No	No	El estudio propone y evalúa técnicas para clasificar texto con Naive Bayes mediante experimentación sobre colecciones estándar de prueba. Presenta medición de desempeño y comparación de resultados, por lo que corresponde a un enfoque cuantitativo [1].
[2]	Sí	No	No	La investigación aplica un método basado en ontología y Naive Bayes sobre un conjunto de datos pequeño, usando validación cruzada y métricas de clasificación. La lógica del trabajo es experimental y medible, no interpretativa, así que se clasifica como cuantitativa [2].
[3]	Sí	No	No	El artículo estudia el comportamiento de Naive Bayes para clasificación de texto en clases desbalanceadas y verifica su rendimiento mediante evaluación empírica. Al centrarse en resultados numéricos y comparación de desempeño, corresponde al enfoque cuantitativo [3].



[4]	Sí	No	No	El trabajo propone un enfoque bayesiano para comparar el rendimiento de clasificadores de texto usando datos de experimentación y análisis estadístico. La investigación se apoya en evidencia cuantificable, por lo que es claramente cuantitativa [4].
[5]	Sí	No	No	El estudio introduce ponderación profunda de características para Naive Bayes y la valida en 36 conjuntos de datos de referencia. Debido a que usa experimentación, métricas de desempeño y comparación de modelos, el enfoque es cuantitativo [5].

La revisión permitió concluir que la investigación sobre Naive Bayes en clasificación de texto está dominada por estudios cuantitativos porque el interés principal es medir desempeño, precisión, estabilidad y mejora del modelo. Aunque algunos trabajos incorporan conocimiento semántico o de dominio, el procedimiento general sigue siendo experimental y medible [1]–[5], [9], [12], [13].




Figura 3: Comparación de enfoques de investigación cuantitativa en estudios de clasificación de texto mediante Naive Bayes.

5.3.4. Mapa conceptual del problema (AA3)

El mapa conceptual permitió articular el problema de investigación con su contexto, actores, variables y posibles objetivos. Además, fue una herramienta útil para alinear el proyecto con la línea de investigación institucional de la UNL [11].




Figura 4: Mapa conceptual del problema de investigación, el contexto, los actores, las variables y los objetivos.

El problema central se ubica en la clasificación automática de texto con Naive Bayes, especialmente cuando se trabaja con textos cortos, datos limitados, clases desbalanceadas o dominios especializados. El contexto académico corresponde al área de sistemas inteligentes y minería de texto, donde la investigación busca mejorar el tratamiento de información textual y la toma de decisiones basada en datos [11].

Los actores involucrados incluyen usuarios que generan o consumen textos, especialistas que validan categorías, desarrolladores que implementan modelos, e instituciones que administran grandes volúmenes documentales. Las variables principales son la precisión de clasificación, la longitud del texto, el tamaño del dataset, el balance de clases, la representación de características y la capacidad de generalización [2], [3], [9], [13].

El mapa conceptual también permitió visualizar posibles objetivos de mejora, como aumentar la precisión del clasificador, fortalecer su robustez frente a textos breves y clases desbalanceadas, e incorporar representaciones más eficientes de las características textuales. En este sentido, el mapa no fue solo una representación visual, sino una herramienta de delimitación conceptual y metodológica.

5.3.5. Formulación de objetivos y pregunta de investigación (APE4)

A partir del problema delimitado y de la evidencia bibliográfica, se formuló la pregunta de investigación principal:

¿Qué tan efectivo es Naive Bayes en clasificación de texto?

La formulación de objetivos se organizó en tres niveles que muestran la evolución de la investigación: descriptivo, aplicado y experimental. Esta diferenciación permitió establecer una ruta coherente para el estudio.

Tabla 4: Preguntas y objetivos formulados

Tipo de investigación	Pregunta	Propósito
Descriptiva	¿Cuáles son las características del rendimiento del clasificador Naive Bayes al analizar textos cortos en conjuntos de datos pequeños y con clases desbalanceadas?	Describir el comportamiento del modelo.
Aplicada	¿De qué manera la ponderación de características mejora el desempeño de Naive Bayes en clasificación de textos cortos?	Resolver un problema práctico mediante una mejora técnica.
Experimental	¿Qué efecto produce la incorporación de ponderación de características al comparar Naive Bayes estándar con una versión mejorada?	Verificar de manera controlada si la modificación introduce mejora real.

La formulación de objetivos mostró que el problema no se limita a estudiar si Naive Bayes funciona o no, sino a determinar bajo qué condiciones funciona mejor y qué adaptaciones permiten incrementar su desempeño. Esto coincide con la literatura revisada, donde las mejoras más consistentes aparecen cuando se combinan técnicas de selección y ponderación de características, suavizado, tratamiento del desbalance y variantes estructurales del modelo [2]–[10].

5.3.6. Recolección de 20 fuentes bibliográficas (APE5)

La recolección de 20 fuentes bibliográficas permitió ampliar la visión inicial y consolidar un corpus más robusto para el estado del arte. Esta fase fue clave porque transformó una búsqueda preliminar de pocos artículos en una base documental más amplia, organizada y útil para la trazabilidad del proyecto.

Tabla 6: Matriz bibliográfica a partir de las 20 fuentes

Autor(es)	Año	Título	Tipo de fuente	Resumen del aporte	Método usado	Hallazgos clave
Sang Bum Kim, Kyoung Soo Han, Hae Chang Rim, Sung Hyon Myaeng	2006	Some effective techniques for naive bayes text classification	Artículo de revista (IEEE)	Propone mejoras prácticas para corregir debilidades del Naive Bayes en clasificación de texto.	Normalización por documento y ponderación de características.	Las mejoras incrementan notablemente la precisión y compiten con clasificadores como SVM.
Ketkaew Sangoun-pao, Pornsiri Muenchaisri	2019	Ontology-Based Naive Bayes Short Text Classification Method for a Small Dataset	Artículo de conferencia (IEEE)	Presenta una estrategia para clasificar texto corto en un dominio contable con pocos datos.	Bolsa de palabras basada en ontología + Naive Bayes + validación cruzada.	Supera el 80 % de clasificación correcta y mejora frente a métodos tradicionales.
Eibe Frank, Remco R. Bouckaert	2006	Naive Bayes for Text Classification with Unbalanced Classes	Capítulo de libro / conferencia (Springer)	Analiza cómo Naive Bayes se comporta con clases desbalanceadas en clasificación documental.	Transformaciones de datos y ajuste de priors/atributos.	Las correcciones mejoran el AUC y hacen más robusto el MNB en clases desbalanceadas.
Dell Zhang, Jun Wang, Emine Yilmaz, Xiaoling Wang, Yuxin Zhou	2016	Bayesian Performance Comparison of Text Classifiers	Artículo de conferencia (ACM)	Propone una forma bayesiana de comparar clasificadores de texto con mayor poder estadístico.	Modelo bayesiano para comparación de desempeño.	Aporta una alternativa más informativa que pruebas frecuentistas tradicionales.
Liangxiao Jiang, Chaoqun Li, Shasha Wang, Lungan Zhang	2016	Deep feature weighting for naive Bayes and its application to text classification	Artículo de revista (ScienceDirect)	Mejora Naive Bayes mediante ponderación profunda de características.	Feature weighting profundo aplicado a frecuencias condicionales.	En múltiples conjuntos de datos mejora o mantiene el rendimiento frente a NB estándar.

Autor(es)	Año	Título	Tipo de fuente	Resumen del aporte	Método usado	Hallazgos clave
Sang-Bum Kim, Hae-Chang Rim, DongSuk Yook, Heui-Seok Lim	2002	Effective Methods for Improving Naive Bayes Text Classifiers	Capítulo de libro / conferencia (Springer)	Presenta técnicas generales para mejorar NB en texto.	Estimación basada en modelo documental, normalización de longitud y ponderación por mutual information.	Las técnicas producen mejoras significativas sobre el NB multinomial tradicional.
Karl-Michael Schneider	2005	Techniques for Improving the Performance of Naive Bayes for Text Classification	Capítulo de libro / conferencia (Springer)	Examina por qué NB pierde rendimiento y cómo corregirlo de forma simple.	Correcciones para modelado textual, selección de características y scores de confianza.	Las modificaciones propuestas mejoran significativamente la clasificación.
Feng He, Xiaoqing Ding	2007	Improving Naive Bayes Text Classifier Using Smoothing Methods	Capítulo de libro / conferencia (Springer)	Explora métodos de suavizado para estabilizar estimaciones en NB.	Diferentes técnicas de smoothing para estimar parámetros.	Los métodos propuestos superan a Laplace smoothing en estabilidad y desempeño.
Ashraf M. Kibriya, Eibe Frank, Bernhard Pfahringer, Geoffrey Holmes	2005	Multinomial Naive Bayes for Text Categorization Revisited	Capítulo de libro / conferencia (Springer)	Revisa y compara variantes de Naive Bayes multinomial para categorización de texto.	Experimentos comparativos; TF-IDF, normalización y aprendizaje ponderado local.	TF-IDF y normalización ayudan; SVM aún puede superar a NB en varios conjuntos.
Ling Yin, Richard Power	2006	Adapting the Naive Bayes Classifier to Rank Procedural Texts	Capítulo de libro / conferencia (Springer)	Adapta NB para ranking de textos procedimentales en la web.	Clasificación/ranking con Naive Bayes y selección de rasgos distintivos.	Funciona bien cuando se usan características altamente informativas.
Jingnian Chen, Houkuan Huang, Shengfeng Tian, Youli Qu	2009	Feature selection for text classification with Naïve Bayes	Artículo de revista (ScienceDirect)	Propone métricas de selección de rasgos específicas para NB.	MOR y CDM para selección de características.	Las métricas propuestas mejoran claramente la selección y la precisión.

Autor(es)	Año	Título	Tipo de fuente	Resumen del aporte	Método usado	Hallazgos clave
Wei Zhang, Feng Gao	2011	An Improvement to Naive Bayes for Text Classification	Artículo de revista / congreso (ScienceDirect)	Introduce una característica auxiliar para mejorar la clasificación con NB.	Método de feature auxiliar y ajuste de probabilidades condicionales.	La propuesta mejora la exactitud frente al NB convencional.
Guozhong Feng, Jianhua Guo, Bing-Yi Jing, Tieli Sun	2015	Feature subset selection using naive Bayes for text classification	Artículo de revista (ScienceDirect)	Plantea una selección de subconjuntos de características con base probabilística.	LSAN Bayes con índices locales y globales de selección.	Supera métodos de ponderación comparados y compite bien con SVM.
Eunseog Youn, Myong K. Jeong	2009	Class dependent feature scaling method using naive Bayes classifier for text datamining	Artículo de revista (ScienceDirect)	Propone una escala de características dependiente de la clase para NB en minería de texto.	Class-dependent feature weighting + recursive feature elimination.	El esquema CDFW-NB-RFE supera esquemas populares de ranking de rasgos.
Lungan Zhang, Liang-xiao Jiang, Chaoqun Li, Ganggang Kong	2016	Two feature weighting approaches for naive Bayes text classifiers	Artículo de revista (ScienceDirect)	Presenta dos enfoques de ponderación para mejorar NB en texto.	Adaptación de técnicas de feature weighting y gain ratio.	Aumenta la precisión manteniendo simplicidad y bajo costo computacional.
Wang Ding, Songnian Yu, Qian-feng Wang, Jiaqi Yu, Qiang Guo	2008	A Novel Naive Bayesian Text Classifier	Artículo de conferencia (IEEE)	Propone un clasificador NB que relaja la independencia condicional.	Package and combined naive Bayesian text classifier (PC-NB).	Mejora la exactitud cuando las características están fuertemente correlacionadas.
Khalil M. El Hindi, Reem R. Aljulaidan, Hussien AlSalman	2020	Lazy fine-tuning algorithms for naïve Bayesian text classification	Artículo de revista (ScienceDirect)	Introduce una estrategia de ajuste local para NB en clasificación de texto.	Lazy fine-tuning con vecinos cercanos; variantes para multinomial, complement y one-vs-all NB.	Mejora NB clásico y sus variantes en varios conjuntos de datos.

Autor(es)	Año	Título	Tipo de fuente	Resumen del aporte	Método usado	Hallazgos clave
Shing-Hwa Lu, Ding-An Chiang, Huan-Chao Keh, Hui-Hua Huang	2010	Chinese text classification by the Naïve Bayes Classifier and the associative classifier with multiple confidence threshold values	Artículo de revista (ScienceDirect)	Combina Naive Bayes con clasificadores asociados para mejorar el texto en chino.	Híbrido NB + reglas de asociación con umbrales de confianza múltiples.	El enfoque combinado mejora el resultado respecto a usar un solo clasificador.
Han-joon Kim, Jiyun Kim, Jin-seog Kim, Pureum Lim	2018	Towards perfect text classification with Wikipedia-based semantic Naïve Bayes learning	Artículo de revista (ScienceDirect)	Integra semántica basada en Wikipedia para enriquecer NB.	Semantic Naïve Bayes learning con tensor space model.	Reporta rendimiento muy alto y superioridad frente a varios enfoques recientes.
Wenyuan Dai, Gui-Rong Xue, Qiang Yang, Yong Yu	2007	Transferring naive bayes classifiers for text classification	Artículo de conferencia (ACM)	Propone transfer learning con NB para cuando los datos de entrenamiento y prueba difieren.	NB con EM para adaptar probabilidades entre dominios.	Supera métodos supervisados y semi-supervisados cuando hay cambio de distribución.

El corpus de 20 fuentes permitió observar que la efectividad de Naive Bayes depende de la técnica de mejora empleada, del dominio del problema y del tipo de datos. En la mayoría de los casos, los estudios no reemplazan al algoritmo base, sino que intentan corregir sus limitaciones clásicas para volverlo más competitivo [1]–[15].




Figura 5: Corpus bibliográfico organizado en un gestor de referencias para estudios de Naive Bayes.

5.3.7. Estrategia de búsqueda avanzada (APE6)

La búsqueda avanzada fue una etapa metodológica decisiva porque permitió pasar de una exploración inicial a una estrategia más formal y reproducible. Se utilizaron operadores booleanos, sinónimos en inglés y filtros de recuperación en Scopus e IEEE Xplore.

Cadena de búsqueda utilizada

```
("naive bayes" OR "naive bayes classifier" OR "naive bayes classification" OR
"bayes classifier" OR "multinomial naive bayes" OR "bernoulli naive bayes")
AND
("text classification" OR "document classification" OR "text categor*" OR
"text mining" OR "text analytics" OR "natural language processing" OR "NLP" OR
"sentiment analysis" OR "topic classification" OR "document categor*")
```

Tabla 7: Componentes de la estrategia de búsqueda

Componente	Descripción
Término principal	Naive Bayes y sus variantes
Dominio temático	Clasificación de texto, minería de texto y PLN
Operadores	AND, OR
Filtros	Año, tipo de documento, área temática e idioma
Resultado	44 artículos recuperados y clasificados

El uso de operadores booleanos permitió ampliar o restringir la búsqueda según la necesidad. OR se empleó para incluir variantes del término principal y sinónimos; AND conectó el algoritmo

con el dominio textual. Esta estrategia facilitó una recuperación más precisa y redujo el ruido documental.



Figura 6: Estrategia de búsqueda avanzada utilizada en Scopus e IEEE Xplore.

Clasificación general de los 44 artículos


Los 44 artículos recuperados se organizaron en una jerarquía de relevancia. Los estudios de **alto** nivel se enfocan directamente en mejorar Naive Bayes, comparar su rendimiento o desarrollar variantes fundamentales; los de **nivel medio** se orientan a aplicaciones específicas en dominios concretos.

Tabla 9: Clasificación de los 44 artículos

#	Nivel de Relevancia	DOI o URL del Artículo
[1]	Alto	10.1109/TKDE.2006.180
[2]	Medio	10.1109/SNPD.2019.8935711
[3]	Alto	10.1007/11871637_49
[4]	Alto	10.1145/2911451.2911547
[5]	Alto	10.1016/J.ENGAPPAI.2016.02.002
[6]	Alto	https://doi.org/10.1007/3-540-45683-X_45
[7]	Alto	https://doi.org/10.1007/978-3-540-30586-6_76
[8]	Alto	https://doi.org/10.1007/978-3-540-71496-5_73
[9]	Alto	https://doi.org/10.1007/978-3-540-30549-1_43
[10]	Medio	https://doi.org/10.1007/11735106_17
[11]	Alto	10.1016/j.eswa.2008.06.054
[12]	Alto	10.1016/j.proeng.2011.08.404
[13]	Alto	10.1016/j.patrec.2015.07.028
[14]	Alto	10.1016/j.patrec.2008.11.013
[15]	Alto	10.1016/j.knosys.2016.02.017
[16]	Alto	10.1109/ISIP.2008.54
[17]	Alto	10.1016/j.asoc.2020.106652
[18]	Medio	10.1016/j.knosys.2010.04.004
[19]	Alto	10.1016/j.neucom.2018.07.002
[20]	Alto	https://dl.acm.org/doi/10.5555/1619645.1619732
[21]	Medio	10.32604/cmes.2023.026812
[22]	Medio	10.55151/ijeedu.v5i1.99
[23]	Medio	10.62441/nano-ntp.v20iS1.77
[24]	Medio	10.38094/jastt61237
[25]	Medio	10.3390/bdcc7030127
[26]	Medio	10.1063/5.0110821
[27]	Medio	10.1016/j.fraope.2025.100373
[28]	Alto	10.1007/s11634-023-00536-8
[29]	Medio	10.1051/e3sconf/202346502048
[30]	Medio	10.1109/ACCESS.2024.3487311

#	Nivel de Relevancia	DOI o URL del Artículo
[31]	Alto	10.26615/978-954-452-056-4_151
[32]	Medio	10.1088/1742-6596/1641/1/012043
[33]	Alto	10.5220/0010890400003122
[34]	Alto	10.1109/TKDE.2016.2522427
[35]	Alto	10.3390/math9192378
[36]	Alto	10.1109/TKDE.2010.160
[37]	Alto	10.1007/978-3-642-41278-3_24
[38]	Alto	10.1109/ACCESS.2020.2968984
[39]	Alto	10.1109/TKDE.2016.2563436
[40]	Medio	10.1093/bioinformatics/btl350
[41]	Medio	10.4108/eai.12-10-2019.2296530
[42]	Medio	10.35940/ijeat.A1610.109119
[43]	Medio	10.1186/1471-2105-8-269
[44]	Alto	10.4067/S0718-09342011000300004

Esta clasificación mostró que el corpus no es homogéneo. Una parte importante de la literatura se concentra en mejorar el algoritmo, mientras que otra parte explora su uso en tareas especializadas. Esto es útil para el reporte porque permite separar el estado del arte general de las aplicaciones contextuales.



The screenshot displays the NotebookLM interface. On the left, a sidebar titled 'Fuentes' (Sources) shows a search bar and a list of 44 selected articles. The main content area, titled 'w8 d2 MIC c1 APE6', contains a summary of research on Naive Bayes classification. The summary text is as follows:

Esta colección de investigaciones se centra en optimizar el algoritmo de **Naive Bayes** para mejorar la precisión en la **clasificación automática de textos**. Los autores proponen diversas técnicas para superar limitaciones tradicionales, tales como el uso de **ponderación de características**, **normalización de documentos** y métodos de **selección de atributos** adaptados a dominios específicos. Las fuentes exploran aplicaciones prácticas que van desde el **análisis de sentimientos** en redes sociales hasta la detección de **noticias engañosas** y la organización de literatura biomédica. Varios estudios demuestran que, mediante ajustes en la **estimación de parámetros** o la integración de **ontologías**, este modelo puede competir e incluso superar en eficiencia a métodos más complejos. En conjunto, los trabajos resaltan la vigencia de este clasificador por su **simplicidad computacional** y su capacidad de adaptación ante datos pequeños o desequilibrados. Estas contribuciones teóricas y experimentales buscan perfeccionar la interpretación de **relaciones semánticas** y la eficacia en el procesamiento del lenguaje natural.

Below the summary, there are three questions in a chat-like interface:

- ¿Cómo se puede mejorar Naive Bayes para clasificar textos cortos?
- ¿Cuáles son las técnicas principales para manejar conjuntos de datos desbalanceados?
- ¿En qué aplicaciones de la vida real destaca este algoritmo?

The interface also shows a timestamp 'Hoy • 8:13' and a section titled 'Necesito que clasifiques cada uno de los 44 artículos según su nivel de relevancia (Alto, Medio, Bajo) para el proyecto de investigación que surge en base a la siguiente pregunta: "¿Qué tan efectivo es Naive Bayes en clasificación de texto?". Realízalo en markdown y preséntalo en una tabla que tenga las columnas [# (del 1 al 44), Nivel de Relevancia (Alto, Medio, Bajo), DOI del artículo (si no tiene DOI, usa la URL en vez del DOI)]'.

At the bottom, it states: 'A continuación se presenta la clasificación de los 44 artículos identificados en las fuentes, evaluados según su relevancia para investigar la efectividad de **Naive Bayes (NB)** en la clasificación de textos. Los criterios utilizados son:'.

Figura 7: Flujo de trabajo de clasificación de referencias en NotebookLM para los 44 artículos seleccionados parte 1.

• Alto: El artículo se centra específicamente en mejorar el algoritmo, comparar su rendimiento de forma exhaustiva o proponer variantes fundamentales. • Medio: El artículo aplica NB a un dominio, idioma o tarea específica (ej. medicina, árabe, detección de clickbait), priorizando la aplicación sobre el estudio teórico de la efectividad general del algoritmo.		
#	Nivel de Relevancia	DOI o URL del Artículo
1	Alto	10.1109/TKDE.2006.180 1 2
2	Medio	10.1109/SNPD.2019.8935711 3 -
3	Alto	10.1007/11871637_49 5 6
4	Alto	10.1145/2911451.2911547 7 8
5	Alto	10.1016/J.ENGAPPAL.2016.02.002 9 10
6	Alto	https://doi.org/10.1007/3-540-45683-X_45 10 11
7	Alto	https://doi.org/10.1007/978-3-540-30586-6_76 12
8	Alto	https://doi.org/10.1007/978-3-540-71496-5_73 13
9	Alto	https://doi.org/10.1007/978-3-540-30549-1_43 14
10	Medio	https://doi.org/10.1007/11735106_17 15 16
11	Alto	10.1016/j.eswa.2008.06.054 17 18
12	Alto	10.1016/j.proeng.2011.08.404 19
13	Alto	10.1016/j.patrec.2015.07.028 20 21
14	Alto	10.1016/j.patrec.2008.11.013 22 23
15	Alto	10.1016/j.knosys.2016.02.017 24 25
16	Alto	10.1109/ISIP.2008.54 25 26
17	Alto	10.1016/j.asoc.2020.106652 27 28
18	Medio	10.1016/j.knosys.2010.04.004 29 30
19	Alto	10.1016/j.neucom.2018.07.002 31 32
20	Alto	https://dl.acm.org/doi/10.5555/1619645.1619732 32 33
21	Medio	10.32604/cmes.2023.026812 34 35
22	Medio	10.55151/ijeedu.v5i1.99 36 37
23	Medio	10.62441/nano-ntp.v20iS1.77 38 39
24	Medio	10.38094/jastt61237 40 41
25	Medio	10.3390/bdcc7030127 42 43
26	Medio	10.1063/5.0110821 44 45
27	Medio	10.1016/j.fragpa.2025.100373 46 47

Figura 8: Flujo de trabajo de clasificación de referencias en NotebookLM para los 44 artículos seleccionados parte 2.

27	Medio	10.1010/jrtaope.2023.100373	45	46
28	Alto	10.1007/s11634-023-00536-8	47	48
29	Medio	10.1051/e3sconf/202346502048	49	50
30	Medio	10.1109/ACCESS.2024.3487311	51	52
31	Alto	10.26615/978-954-452-056-4_151	53	54
32	Medio	10.1088/1742-6596/1641/1/012043	55	56
33	Alto	10.5220/0010890400003122	57	58
34	Alto	10.1109/TKDE.2016.2522427	59	60
35	Alto	10.3390/math9192378	61	
36	Alto	10.1109/TKDE.2010.160	62	63
37	Alto	10.1007/978-3-642-41278-3_24	64	65
38	Alto	10.1109/ACCESS.2020.2968984	66	67
39	Alto	10.1109/TKDE.2016.2563436	68	69
40	Medio	10.1093/bioinformatics/btl350	70	71
41	Medio	10.4108/eai.12-10-2019.2296530	72	73
42	Medio	10.35940/ijeat.A1610.109119	74	75
43	Medio	10.1186/1471-2105-8-269	76	77
44	Alto	10.4067/S0718-09342011000300004	78	79

Guardar como nota

Haz una pregunta o crea algo

1 fuente

NotebookLM puede ofrecer respuestas inexactas. Compruébalas.

Figura 9: Flujo de trabajo de clasificacion de referencias en NotebookLM para los 44 artículos seleccionados parte 3.

5.3.8. Redacción de antecedentes iniciales (AA6)

La etapa de antecedentes permitió redactar una primera síntesis académica del estado del conocimiento sobre la efectividad de Naive Bayes en clasificación de texto. Este apartado resultó clave porque conectó la evidencia dispersa en una narrativa coherente y orientada a la pregunta de investigación.

Naive Bayes ha sido usado como modelo base en clasificación textual debido a su eficiencia y simplicidad [1]. Sin embargo, su comportamiento mejora cuando se incorporan normalización por documento, ponderación de características y ajustes en la representación textual [2], [5], [6], [7]. También se ha evidenciado que el modelo presenta limitaciones cuando las clases están desbalanceadas o cuando el conjunto de datos es pequeño [3], [4], [13].

Otros estudios han mostrado que el supuesto de independencia condicional puede ser demasiado restrictivo, por lo que se han propuesto variantes de orden superior, adaptaciones semánticas y mecanismos de ajuste local [8], [9], [10], [15]. En paralelo, trabajos de comparación bayesiana han ayudado a interpretar de forma más rigurosa las diferencias de desempeño entre clasificadores [12]. Esto refuerza la idea de que la efectividad de Naive Bayes no debe juzgarse solo por un resultado aislado, sino por su comportamiento en diferentes condiciones de evaluación.

Los antecedentes también muestran que Naive Bayes sigue siendo útil en aplicaciones concretas como análisis de sentimientos, clasificación de reseñas, textos cortos y dominios especializados [13], [14], [15]. Por ello, la brecha principal no es la ausencia de evidencia, sino la dispersión de los

resultados y la falta de una síntesis unificada sobre su efectividad general. En consecuencia, la investigación se orienta a reunir y organizar la literatura para determinar bajo qué circunstancias el modelo funciona adecuadamente y en cuáles pierde competitividad.

5.4. Estado actual del proyecto

El proyecto se encuentra en una etapa de consolidación intermedia-avanzada. Ya se dispone de una pregunta de investigación clara, un problema delimitado, un corpus bibliográfico de 44 artículos, una matriz inicial de cinco estudios, un análisis de brechas, una tabla de enfoques, un mapa conceptual, objetivos formulados, búsqueda avanzada documentada y antecedentes iniciales redactados.

Desde el punto de vista organizativo, el repositorio GitHub se estructura de forma coherente con la trazabilidad requerida:

Tabla 10: Estructura del repositorio GitHub

Carpeta	Contenido esperado
docs/	Reporte técnico, documento del proyecto, capítulo del libro, presentaciones y evidencias finales.
src/	Scripts, notebooks y cualquier código de apoyo al análisis.
data/	Matrices, tablas, archivos CSV/XLSX, PDFs de artículos y demás insumos de evidencia.
refs/	Archivos bibliográficos BibTeX, exportaciones de Zotero/Mendeley y referencias organizadas.

La documentación ya permite seguir la evolución del proyecto paso a paso. En particular, el trabajo realizado evidencia una secuencia metodológica sólida: búsqueda inicial, análisis crítico, ampliación del corpus, búsqueda avanzada, redacción de antecedentes y organización institucional de la línea de investigación [11]. Esto hace posible que el APE7 funcione como una integración real de todo lo construido durante la unidad.




Figura 10: Repositorio estructurado de GitHub para la trazabilidad de la investigación.

5.5. Preguntas de control

1. ¿Qué ventajas ofrece Overleaf para la escritura académica colaborativa?

Overleaf permite redactar documentos académicos en LaTeX de forma colaborativa y en línea, sin necesidad de instalar software complejo en cada equipo. Además, facilita la gestión de referencias, el control de versiones, la integración de figuras y tablas, y la producción de documentos con formato profesional y consistente. En un proyecto de investigación, esto reduce errores de maquetación y mejora la organización del manuscrito.

2. ¿Cómo contribuye GitHub a la trazabilidad del proceso investigativo?

GitHub permite registrar cada cambio realizado en archivos, scripts, tablas y documentos del proyecto mediante commits, ramas y repositorios organizados. Esto hace posible revisar la evolución del trabajo, identificar qué evidencia se añadió en cada etapa y conservar una historia clara del proceso investigativo. En consecuencia, GitHub funciona como un sistema de trazabilidad académica y técnica que respalda la transparencia y la reproducibilidad del proyecto.

5.6. Conclusiones

La evidencia revisada confirma que Naive Bayes sí es una técnica efectiva para clasificación de texto, pero su rendimiento depende fuertemente del contexto de aplicación. En particular, los estudios muestran mejoras significativas cuando se incorporan técnicas de normalización, ponderación de características, selección de atributos, suavizado, ajustes por desbalance y variantes estructurales del modelo [1]–[10].

El desarrollo de las actividades permitió construir una trazabilidad clara del proceso investigativo. Desde la primera selección de cinco artículos hasta la consolidación de un corpus de 44 fuentes, el proyecto avanzó de forma progresiva y metodológicamente consistente. Esto demuestra que el APE7 no es un trabajo aislado, sino la unificación de los productos elaborados durante la unidad.

También se concluye que la efectividad de Naive Bayes no puede evaluarse de forma universal, sino de manera contextual. El algoritmo puede rendir muy bien en ciertos escenarios, especialmente cuando se adapta a textos cortos, datos escasos o clases desbalanceadas, pero requiere ajustes para competir con clasificadores más sofisticados [3], [8], [9], [12], [13].

Finalmente, el proyecto se encuentra alineado con la línea de investigación institucional de la UNL y con la sublínea de inteligencia artificial y aprendizaje automático [11]. Esto le da pertinencia académica, coherencia temática y proyección para futuras etapas del trabajo.

6. Referencias

Referencias

- [1] S. B. Kim, K. S. Han, H. C. Rim, and S. H. Myaeng, "Some effective techniques for naive bayes text classification," *IEEE Transactions on Knowledge and Data Engineering*, vol. 18, pp. 1457–1466, 11 2006. [Online]. Available: <https://ieeexplore.ieee.org/document/1704799>
- [2] K. Sangounpao and P. Muenchaisri, "Ontology-based naive bayes short text classification method for a small dataset," *Proceedings - 20th IEEE/ACIS International Conference on Software Engineering, Artificial Intelligence, Networking and Parallel/Distributed Computing, SNPD 2019*, pp. 53–58, 7 2019. [Online]. Available: <https://ieeexplore.ieee.org/document/8935711>
- [3] E. Frank and R. R. Bouckaert, "Naive bayes for text classification with unbalanced classes," *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, vol. 4213 LNAI, pp. 503–510, 2006. [Online]. Available: https://link.springer.com/chapter/10.1007/11871637_49
- [4] D. Zhang, J. Wang, E. Yilmaz, X. Wang, and Y. Zhou, "Bayesian performance comparison of text classifiers," in *Proceedings of the 39th International ACM SIGIR Conference on Research and Development in Information Retrieval*, ser. SIGIR '16. New York, NY, USA: Association for Computing Machinery, 2016, p. 15–24. [Online]. Available: <https://doi.org/10.1145/2911451.2911547>
- [5] L. Jiang, C. Li, S. Wang, and L. Zhang, "Deep feature weighting for naive bayes and its application to text classification," *Engineering Applications of Artificial Intelligence*, vol. 52,

- pp. 26–39, 6 2016. [Online]. Available: <https://www.sciencedirect.com/science/article/abs/pii/S0952197616300112?via%3Dihub>
- [6] S.-B. Kim, H.-C. Rim, D. Yook, and H.-S. Lim, “Effective methods for improving naive bayes text classifiers,” in *PRICAI 2002: Trends in Artificial Intelligence*, M. Ishizuka and A. Sattar, Eds. Berlin, Heidelberg: Springer Berlin Heidelberg, 2002, pp. 414–423.
 - [7] K.-M. Schneider, “Techniques for improving the performance of naive bayes for text classification,” in *Computational Linguistics and Intelligent Text Processing*, A. Gelbukh, Ed. Berlin, Heidelberg: Springer Berlin Heidelberg, 2005, pp. 682–693.
 - [8] F. He and X. Ding, “Improving naive bayes text classifier using smoothing methods,” in *Advances in Information Retrieval*, G. Amati, C. Carpineto, and G. Romano, Eds. Berlin, Heidelberg: Springer Berlin Heidelberg, 2007, pp. 703–707.
 - [9] A. M. Kibriya, E. Frank, B. Pfahringer, and G. Holmes, “Multinomial naive bayes for text categorization revisited,” in *AI 2004: Advances in Artificial Intelligence*, G. I. Webb and X. Yu, Eds. Berlin, Heidelberg: Springer Berlin Heidelberg, 2005, pp. 488–499.
 - [10] L. Yin and R. Power, “Adapting the naive bayes classifier to rank procedural texts,” in *Advances in Information Retrieval*, M. Lalmas, A. MacFarlane, S. Rüger, A. Tombros, T. Tsikrika, and A. Yavilinsky, Eds. Berlin, Heidelberg: Springer Berlin Heidelberg, 2006, pp. 179–190.
 - [11] J. Chen, H. Huang, S. Tian, and Y. Qu, “Feature selection for text classification with naïve bayes,” *Expert Systems with Applications*, vol. 36, no. 3, Part 1, pp. 5432–5435, 2009. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0957417408003564>
 - [12] W. Zhang and F. Gao, “An improvement to naive bayes for text classification,” *Procedia Engineering*, vol. 15, pp. 2160–2164, 2011, cEIS 2011. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1877705811019059>
 - [13] G. Feng, J. Guo, B.-Y. Jing, and T. Sun, “Feature subset selection using naive bayes for text classification,” *Pattern Recognition Letters*, vol. 65, pp. 109–115, 2015. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0167865515002378>
 - [14] E. Youn and M. K. Jeong, “Class dependent feature scaling method using naive bayes classifier for text datamining,” *Pattern Recognition Letters*, vol. 30, no. 5, pp. 477–485, 2009. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0167865508003553>
 - [15] L. Zhang, L. Jiang, C. Li, and G. Kong, “Two feature weighting approaches for naive bayes text classifiers,” *Knowledge-Based Systems*, vol. 100, pp. 137–144, 2016. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0950705116001039>
 - [16] W. Ding, S. Yu, Q. Wang, J. Yu, and Q. Guo, “A novel naive bayesian text classifier,” in *2008 International Symposiums on Information Processing*, May 2008, pp. 78–82.
 - [17] K. M. El Hindi, R. R. Aljulaidan, and H. AlSalman, “Lazy fine-tuning algorithms for naïve bayesian text classification,” *Applied Soft Computing*, vol. 96, p. 106652, 2020. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1568494620305901>
 - [18] S.-H. Lu, D.-A. Chiang, H.-C. Keh, and H.-H. Huang, “Chinese text classification by the naïve bayes classifier and the associative classifier with multiple confidence threshold values,” *Knowledge-Based Systems*, vol. 23, no. 6, pp. 598–604, 2010. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0950705110000638>
 - [19] H. joon Kim, J. Kim, J. Kim, and P. Lim, “Towards perfect text classification with wikipedia-based semantic naïve bayes learning,” *Neurocomputing*, vol. 315, pp. 128–134, 2018. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0925231218308282>
 - [20] W. Dai, G.-R. Xue, Q. Yang, and Y. Yu, “Transferring naive bayes classifiers for text classification,” in *Proceedings of the 22nd National Conference on Artificial Intelligence - Volume 1*, ser. AAAI’07. AAAI Press, 2007, p. 540–545. [Online]. Available: <https://dl.acm.org/doi/10.5555/1619645.1619732>
 - [21] J. B. Awotunde, S. Misra, V. Katta, and O. C. Adebayo, “An ensemble-based hotel reviews system using naive bayes classifier,” *CMES - Computer Modeling in Engineering and Sciences*, vol. 137, no. 1, pp. 131 – 154, 2023, cited by: 9; All Open Access; Gold Open Access; Green Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/85159167415?origin=resultlist>

- [22] A. A. N. Risal, Fathahillah, and D. R. A. Sulaiman, "Classification of sentiment analysis and community opinion modeling topics for application of ict in government operations," *International Journal of Environment, Engineering and Education*, vol. 5, no. 1, pp. 35 – 44, 2023, cited by: 1; All Open Access; Gold Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/105008537656?origin=resultslist>
- [23] C. Sawlani and P. Sharma, "A nano scale machine learning assisted natural language processing framework for sentiment classification in smart system platform," *Nanotechnology Perceptions*, vol. 20, no. S1, pp. 952 – 966, 2024, cited by: 0; All Open Access; Gold Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/85200108878?origin=resultslist>
- [24] N. O. Lwin, R. Jain, R. Dal, H. O. Yan, K. K. Thaw, and S. Y. Naung, "Text classification for clickbait detection: A model-driven approach using countvectorizer and ml classifiers," *Journal of Applied Science and Technology Trends*, vol. 6, no. 1, pp. 43 – 49, 2025, cited by: 4; All Open Access; Gold Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/105009105858?origin=resultslist>
- [25] D. A. Musleh, I. Alkhwaja, A. Alkhwaja, M. Alghamdi, H. Abahussain, F. Alfawaz, N. Min-Allah, and M. M. Abdulqader, "Arabic sentiment analysis of youtube comments: Nlp-based machine learning approaches for content evaluation," *Big Data and Cognitive Computing*, vol. 7, no. 3, 2023, cited by: 44; All Open Access; Gold Open Access; Green Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/85172102206?origin=resultslist>
- [26] M. F. Mazidnianto, A. P. Damanik, I. Budi, A. B. Santoso, and P. K. Putra, "Abortion drug products classification using text mining: A case study of pt xyz," vol. 2658, 2022, Conference paper, cited by: 0; All Open Access; Bronze Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/85144139461?origin=resultslist>
- [27] B. Shannaq, "Enhancing arabic text classification through mobile virtual keypad-based encoding algorithm," *Franklin Open*, vol. 12, 2025, cited by: 5; All Open Access; Gold Open Access; Green Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/105017785466?origin=resultslist>
- [28] M. Romano, G. Contu, F. Mola, and C. Conversano, "Threshold-based naïve bayes classifier," *Advances in Data Analysis and Classification*, vol. 18, no. 2, pp. 325 – 361, 2024, cited by: 15; All Open Access; Green Open Access; Hybrid Gold Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/85149965773?origin=resultslist>
- [29] M. H. Humaidi, Sutrisno, and P. W. Laksono, "Implementation of machine learning for text classification using the naive bayes algorithm in academic information systems at sebelas maret university indonesia," vol. 465, 2023, Conference paper, cited by: 0; All Open Access; Gold Open Access; Green Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/85182782781?origin=resultslist>
- [30]
- [31] A. Wawer and J. Sobiczewska, "Predicting sentiment of polish language short texts," vol. 2019-September, 2019, Conference paper, pp. 1321 – 1327, cited by: 5; All Open Access; Gold Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/85076455857?origin=resultslist>
- [32] D. Pratmanto, R. Rousyati, F. F. Wati, A. E. Widodo, S. Suleman, and R. Wijianto, "App review sentiment analysis shopee application in google play store using naive bayes algorithm," vol. 1641, no. 1, 2020, Conference paper, cited by: 27; All Open Access; Gold Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/85097187731?origin=resultslist>
- [33] E. Azeraf, E. Monfrini, and W. Pieczynski, "Improving usual naive bayes classifier performances with neural naïve bayes based models," vol. 1, 2022, Conference paper, pp. 315 – 322, cited by: 6; All Open Access; Gold Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/85174564063?origin=resultslist>

- [34] B. Tang, H. He, P. M. Baggenstoss, and S. Kay, "A bayesian classification approach using class-specific features for text categorization," *IEEE Transactions on Knowledge and Data Engineering*, vol. 28, no. 6, pp. 1602 – 1606, 2016, cited by: 153; All Open Access; Green Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/84968876693?origin=resultslist>
- [35] S. Gan, S. Shao, L. Chen, L. Yu, and L. Jiang, "Adapting hidden naive bayes for text classification," *Mathematics*, vol. 9, no. 19, 2021, cited by: 19; All Open Access; Gold Open Access; Green Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/85115956966?origin=resultslist>
- [36] M. C. Ganiz, C. George, and W. M. Pottenger, "Higher order naïve bayes: A novel non-iid approach to text classification," *IEEE Transactions on Knowledge and Data Engineering*, vol. 23, no. 7, pp. 1022 – 1034, 2011, cited by: 47; All Open Access; Green Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/80054909897?origin=resultslist>
- [37] V. Narayanan, I. Arora, and A. Bhatia, "Fast and accurate sentiment classification using an enhanced naive bayes model," *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, vol. 8206 LNCS, pp. 194 – 201, 2013, cited by: 202; All Open Access; Green Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/84890866356?origin=resultslist>
- [38] S. Ruan, H. Li, C. Li, and K. Song, "Class-specific deep feature weighting for naïve bayes text classifiers," *IEEE Access*, vol. 8, pp. 20 151 – 20 159, 2020, cited by: 38; All Open Access; Gold Open Access; Green Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/85079740208?origin=resultslist>
- [39] B. Tang, S. Kay, and H. He, "Toward optimal feature selection in naive bayes for text categorization," *IEEE Transactions on Knowledge and Data Engineering*, vol. 28, no. 9, pp. 2508 – 2521, 2016, cited by: 216; All Open Access; Green Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/84982078862?origin=resultslist>
- [40] B. Han, Z. Obradovic, Z.-Z. Hu, C. H. Wu, and S. Vucetic, "Substring selection for biomedical document classification," *Bioinformatics*, vol. 22, no. 17, pp. 2136 – 2142, 2006, cited by: 17; All Open Access; Hybrid Gold Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/33748635165?origin=resultslist>
- [41] J. H. Jaman, Hannie, and M. S. Simatupang, "Sentiment analysis of the body-shaming beauty vlog comments," 2020, Conference paper, cited by: 4; All Open Access; Bronze Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/85127560697?origin=resultslist>
- [42] M. Prabu, M. S. Aithani, N. Deb, and P. Joshi, "Communication sentiment analyzer using machine learning with naive bayes bernoullinb," *International Journal of Engineering and Advanced Technology*, vol. 9, no. 1, pp. 5976 – 5979, 2019, cited by: 0; All Open Access; Gold Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/85074554442?origin=resultslist>
- [43] P. Wang, A. A. Morgan, Q. Zhang, A. Sette, and B. Peters, "Automating document classification for the immune epitope database," *BMC Bioinformatics*, vol. 8, 2007, cited by: 40; All Open Access; Gold Open Access; Green Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/34548493473?origin=resultslist>
- [44] M. Mendoza, I. Ortiz, and V. Rojas, "Text categorization in documentary databases using light computational models; [categorización de texto en bases documentales a partir de modelos computacionales livianos]," *Revista Signos*, vol. 44, no. 77, pp. 251 – 274, 2011, cited by: 0; All Open Access; Bronze Open Access; Green Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/83055180050?origin=resultslist>

7. Anexos

Recursos de apoyo para cada una de las secciones anteriores: capturas de pantalla, matrices de extracción, tablas de análisis, documento de antecedentes, exportación bibliográfica y evidencia del repositorio GitHub.