



Plantilla para la Descripción del Problema Técnico

1. Contexto general del problema

En el área de **Sistemas Inteligentes y Minería de Texto**, las organizaciones y unidades académicas enfrentan desafíos para clasificar automáticamente grandes volúmenes de información textual, especialmente cuando los documentos son breves, presentan vocabulario limitado o pertenecen a dominios específicos. Este problema aparece con frecuencia en entornos **educativos, administrativos e industriales**, donde se requiere organizar textos como requisitos, comentarios, correos, tickets o registros operativos de manera eficiente y consistente [1], [2].

2. Situación actual basada en evidencia

La literatura científica muestra que el clasificador Naive Bayes sigue siendo una alternativa relevante por su simplicidad y eficiencia; sin embargo, su desempeño en clasificación de texto puede verse afectado por problemas en la estimación de parámetros y por la independencia condicional asumida por el modelo [1]. Para mejorar sus resultados, se han propuesto técnicas como la normalización por documento y la ponderación de características, con mejoras observables sobre colecciones de referencia [1].

En textos cortos y conjuntos de datos pequeños, se ha evidenciado que la incorporación de conocimiento de dominio mediante ontologías puede fortalecer la representación tipo bag-of-words y mejorar la clasificación multiclase, alcanzando resultados superiores al 80% en experimentos con validación cruzada [2]. Asimismo, en escenarios con clases desbalanceadas, Naive Bayes presenta limitaciones adicionales que requieren ajustes específicos para conservar su utilidad práctica [3].

Por otro lado, la investigación reciente también ha demostrado que la ponderación profunda de características mejora de forma significativa el rendimiento de Naive Bayes en múltiples conjuntos de datos y en aplicaciones de clasificación textual [4]. Finalmente, la comparación de clasificadores de texto se ha abordado desde enfoques bayesianos más rigurosos, lo que confirma que el análisis experimental y estadístico sigue siendo central en este campo [5].

3. Brecha o vacío identificado

A pesar de los avances reportados, persiste una brecha significativa en el diseño de métodos que integren de forma simultánea **robustez frente a textos cortos, adaptación a dominios específicos, tratamiento de clases desbalanceadas y buen desempeño con conjuntos de datos pequeños**. La evidencia disponible muestra mejoras parciales, pero aún no resuelve por completo la necesidad de un enfoque estable y transferible para contextos con escasez de datos y alta variabilidad semántica [1], [2], [3], [4].



4. Problema central

El problema radica en que los métodos tradicionales de clasificación automática de texto, particularmente Naive Bayes en su forma estándar, presentan limitaciones de precisión y estabilidad al trabajar con textos cortos, datos escasos, clases desbalanceadas y dominios especializados, lo cual afecta la confiabilidad de la categorización automática de información textual [1], [3], [4].

5. Consecuencias o impacto

Esta situación genera consecuencias como **errores de clasificación, baja calidad en la organización de la información y dificultades para automatizar procesos de toma de decisiones**. Además, limita la construcción de sistemas de recuperación y análisis textual confiables, incrementa la carga manual de revisión y reduce la eficiencia en entornos donde la clasificación automática resulta crítica, como la gestión de requisitos, la administración documental y el análisis de comentarios o solicitudes [2], [5], [4].

6. Actores involucrados

Los principales actores involucrados incluyen:

- Usuarios finales que generan o consultan textos.
- Analistas o especialistas que validan categorías.
- Desarrolladores que implementan los modelos de clasificación.
- Instituciones u organizaciones que gestionan grandes volúmenes de información textual.
- Responsables de procesos que dependen de una clasificación automática precisa [2], [5].

7. Variables o elementos clave

Las variables clave asociadas al problema incluyen:

- **Precisión de clasificación:** grado de acierto del modelo al asignar categorías.
- **Longitud del texto:** especialmente relevante en textos cortos.
- **Tamaño del conjunto de datos:** influencia directa en la estabilidad del aprendizaje.
- **Desbalance de clases:** distribución desigual de ejemplos por categoría.
- **Representación de características:** bag-of-words, ponderación de términos y uso de conocimiento de dominio.
- **Capacidad de generalización:** habilidad del método para funcionar en distintos contextos y conjuntos de datos [1], [2], [3], [4].

8. Delimitación del problema



El presente problema se delimita al **análisis y mejora de la clasificación automática de texto en escenarios de datos textuales breves o con pocos ejemplos, usando principalmente enfoques basados en Naive Bayes y variantes de representación de características**. Se excluyen, por tanto, problemas de generación de texto, traducción automática, extracción de información profunda o clasificación basada exclusivamente en redes neuronales de gran escala, salvo como referencia comparativa [1], [2], [4].

9. Vinculación con la sublínea de investigación

Este problema se enmarca dentro de la sublínea de investigación de **Minería de Texto y Sistemas Inteligentes**, debido a que estudia métodos computacionales para organizar, clasificar y mejorar el tratamiento automático de información textual. La relación con esta sublínea se justifica porque el foco está en la optimización de algoritmos de clasificación, la representación de características lingüísticas y la evaluación experimental de su rendimiento en distintos contextos de datos [1], [5], [4].

Referencias

- [1] S. B. Kim, K. S. Han, H. C. Rim, and S. H. Myaeng, "Some Effective Techniques for Naive Bayes Text Classification," *IEEE Transactions on Knowledge and Data Engineering*, vol. 18, no. 11, pp. 1457–1466, Nov. 2006. <https://doi.org/10.1109/TKDE.2006.180>
- [2] K. Sangounpao and P. Muenchaisri, "Ontology-Based Naive Bayes Short Text Classification Method for a Small Dataset," in *Proceedings of the 20th IEEE/ACIS International Conference on Software Engineering, Artificial Intelligence, Networking and Parallel/Distributed Computing (SNPD 2019)*, 2019, pp. 53–58. <https://doi.org/10.1109/SNPD.2019.8935711>
- [3] E. Frank and R. R. Bouckaert, "Naive Bayes for Text Classification with Unbalanced Classes," in *Knowledge Discovery in Databases: PKDD 2006*, Lecture Notes in Computer Science, vol. 4213, J. Fürnkranz, T. Scheffer, and M. Spiliopoulou, Eds. Berlin, Heidelberg: Springer, 2006, pp. 503–510. https://doi.org/10.1007/11871637_49
- [4] L. Jiang, C. Li, S. Wang, and L. Zhang, "Deep Feature Weighting for Naive Bayes and Its Application to Text Classification," *Engineering Applications of Artificial Intelligence*, vol. 52, pp. 26–39, Jun. 2016. <https://doi.org/10.1016/j.engappai.2016.02.002>
- [5] D. Zhang, J. Wang, E. Yilmaz, X. Wang, and Y. Zhou, "Bayesian Performance Comparison of Text Classifiers," in *Proceedings of the 39th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '16)*, New York, NY, USA: ACM, 2016, pp. 15–24. <https://doi.org/10.1145/2911451.2911547>